

# RAPPORT TECHNIQUE

## ECO-SMART CLASSIFIER

*Systeme de classification multimodal et de valorisation des dechets en Tunisie*

---

Ce rapport technique detaille la conception, l'architecture et les resultats des differents modules du projet Eco-Smart. Ce systeme integre des modeles de Machine Learning de classification multimodale, des modeles de regression pour l'estimation de prix, des techniques d'analyse de texte (NLP), du clustering non-supervise, ainsi qu'une infrastructure MLOps complete (DVC, MLflow, CI/CD, Monitoring).

### MODULES DU CAHIER DES CHARGES COUVERTS

- Module 1 : Exploration, Nettoyage et Imputation des Donnees (KNN Imputer)
- Module 2 & 5 : Modelisation Supervisee & Pipeline Multimodal (ColumnTransformer)
  - Module 3 : Clustering Non-Supervise (Elbow, PCA, K-Means)
- Module 4 & 6 : Analyse de Textes (NLP) et Infrastructure MLOps (DVC, MLflow, Evidently)

### Livrable Technique - Projet de Fin d'Etudes

Technologies : Flutter, Django, FastAPI, Scikit-Learn, DVC, MLflow, Evidently AI

Date : Mai 2026

## 1. Introduction et Objectifs du Projet

Dans le cadre de la transition ecologique et de l'economie circulaire, la gestion des dechets represente un enjeu industriel majeur. L'objectif de ce projet est de concevoir et deployer un workflow d'ingenierie des donnees et de Machine Learning complet. Ce workflow va de la donnee brute 'sale' a une application web et mobile connectee a des API d'inference, capable de :

- **Classifieur** : Classifier automatiquement le type de dechet (Plastique, Verre, Metal, Papier).
- **Estimer** : Estimer la valeur marchande de revente en dinars tunisiens (TND).
- **Regrouper** : Regrouper (clustering) les materiaux en sous-categories homogenes.
- **Extraire** : Extraire les caracteristiques cles d'un rapport textuel via un module NLP.

## 2. Pipeline Eco-Smart Classifier : Vue d'ensemble (End-to-End)

Cette section decrit le pipeline bout-en-bout (donnees -> modele -> API -> application -> monitoring), afin de relier les modules techniques en une chaine coherente et reproductible.

### 2.1 Chaine de valeur (donnees -> modeles)

1. Ingestion / sources : donnees tabulaires (mesures physiques), texte (Rapport\_Collecte), et signaux applicatifs.
2. Nettoyage : traitement des valeurs manquantes, outliers, coherence des unites et distributions.
3. Feature engineering : creation de ratios et transformations (Densite, Log\_Volume, etc.).
4. Entrainement supervise : Classification (predire Categorie) et Regression (predire Prix\_Revente).
5. Clustering : segmentation non-supervisee pour analyser des sous-profils de dechets.

### 2.2 Chaine de production (reproductibilite -> serving -> monitoring)

- Reproductibilite donnees / modeles : versionnement (Git) + versionnement des donnees et artefacts (DVC).
- Tracabilite des experimentations : tracking de runs, parametres et metriques (MLflow) et promotion de modeles via Model Registry.
- Serving : un endpoint d'inference (/predict) charge le pipeline serialise et renvoie Categorie + Prix\_Revente.
- Qualite & monitoring : tests unitaires + surveillance de drift (Evidently) et alertes JSON.

### 3. Module 1 : Exploration, Nettoyage et Imputation des Donnees

#### 3.1 Analyse exploratoire (EDA) et types de variables

- Le dataset contient 10 500 enregistrements avec les colonnes suivantes :
- Numeriques : Poids (avec ~10% de valeurs manquantes), Volume (comportant des anomalies/outliers), Conductivite, Opacite, Rigidite et Prix\_Revente (variable cible pour la regression).
  - Categorielles : Source (provenance du dechet : municipal, industriel, etc.).
  - Textuelles : Rapport\_Collecte (description textuelle du lot).
  - Cible : Categorie (type de dechet pour la classification).

#### 3.2 Strategies d'imputation et comparaison quantitative

- Pour traiter les 10% de valeurs manquantes de la colonne Poids, nous avons compare trois approches :
1. Mediane (Baseline) : Simple mais ignore les correlations avec d'autres colonnes.
  2. KNN Imputer (k=5) : Imputation par les k-plus proches voisins en se basant sur la similarite des autres variables numeriques.
  3. Iterative Imputer (MICE) : Modelise chaque feature avec des valeurs manquantes comme une fonction des autres features.

| Strategie d'imputation   | RMSE de reconstruction | Decision technique                  |
|--------------------------|------------------------|-------------------------------------|
| Imputation Mediane       | 112.45                 | Rejetee                             |
| <b>KNN Imputer (k=5)</b> | <b>43.12</b>           | <b>Retenue (Meilleur compromis)</b> |
| Iterative Imputer (MICE) | 48.76                  | Rejetee (Lenteur de calcul)         |

#### Justification technique

- KNN Imputer (k=5) est retenu car il offre la meilleure qualite de reconstruction de poids en capturant les relations avec le Volume et la Rigidite sans introduire le biais de la mediane globale.
- IQR Outliers Capping : Nous avons applique un filtre IQR pour borner les valeurs extremes de Volume et Poids.

## 4. Module 2 & 5 : Modelisation Supervisee et Pipeline Multimodal

### 4.1 Fusion multimodale avec ColumnTransformer

Le pipeline associe le texte vectorise (TF-IDF sur Rapport\_Collecte) et les variables numeriques preprocessees. Cette integration limite les fuites de donnees (data leakage).

### 4.2 Classification : Modeles, Tuning et Analyse Critique

Nous avons evalue plusieurs algorithmes pour la classification multiclasse de la Categorie de dechet :

| Modele                     | Accuracy (val) | F1 pondere (val) | Lecture critique                                  |
|----------------------------|----------------|------------------|---------------------------------------------------|
| Regression Logistique      | 0.9725         | 0.9725           | Baseline solide, limitee aux relations lineaires. |
| RandomForestClassifier     | 0.9964         | 0.9964           | Tres performant, retenu pour production.          |
| GradientBoostingClassifier | 0.9971         | 0.9971           | Legerement superieur, mais plus lent a tuner.     |

### 4.3 Regression (Prix de revente)

Resultats d'estimation du Prix\_Revente sur le jeu de test :

| Modele                    | MAE    | RMSE   | R2     | Lecture critique                                    |
|---------------------------|--------|--------|--------|-----------------------------------------------------|
| Regression Lineaire       | 106.54 | 706.25 | 0.0088 | Insuffisante (sous-apprentissage massif).           |
| RandomForestRegressor     | 3.83   | 36.51  | 0.9974 | Excellent en validation, plus de variance sur test. |
| GradientBoostingRegressor | 19.63  | 82.94  | 0.9863 | Alternative robuste face aux outliers.              |

### 4.4 Explicabilite avec SHAP Values

L'interpretation locale et globale avec SHAP a montre que la Conductivite et la Rigidite sont les facteurs les plus discriminants pour detecter les metaux et le verre. Nous avons elimine 20% des features a impact nul pour simplifier le modele sans perte de performance.

## 5. Module 3 : Clustering Non-Supervise

Afin d'analyser la repartition intrinseque des materiaux sans utiliser les labels de Categorie :

1. Methode du coude (Elbow Method) : L'analyse de l'inertie intra-classe a valide un k optimal de 4 clusters.
2. Reduction PCA 2D : Projection et separation visuelle nette en 2 dimensions.
3. Profils des Clusters :
  - Cluster 0 (Metaux) : Conductivite tres elevee et poids fort.
  - Cluster 1 (Plastiques) : Basse densite, forte opacite.
  - Cluster 2 (Papier/Carton) : Rigidite minimale.
  - Cluster 3 (Verre) : Rigidite maximale et opacite nulle.

## 6. Module 4 : Module NLP (Analyse de Textes)

Les rapports textuels de collecte font l'objet d'un pretraitement (stop-words francais, stemming Snowball). Nous avons evalue quatre modeles de representation vectorielle :

- **Bag of Words (BoW)** : Frequence brute des mots. Ignore le contexte.
- **TF-IDF (Uni + Bigrammes)** : Pondere l'importance relative. Permet d'isoler des termes cles comme 'bouteille plastique' ou 'bris verre'.
- **Word2Vec** : Capture les proximites semantiques dans les descriptions.
- **FastText** : Excellente robustesse aux fautes de frappe frequentes dans les rapports (ex: 'belar', 'hdid', 'kardhoun').

## 7. Module 6 : Infrastructure MLOps, Serving et Monitoring

### 7.1 Reproductibilite avec DVC

L'ensemble du pipeline est defini dans dvc.yaml (preprocess -> train). Executer 'dvc repro' permet de regenerer les modeles de bout en bout de maniere reproductible sans data leakage.

### 7.2 Tracking MLflow et Model Registry

Toutes les experimentations de recherche d'hyperparametres (GridSearchCV) ont ete logguees sur un serveur MLflow local (parametres, accuracy, courbes). Le meilleur modele a ete pousse vers le Model Registry puis promu en 'Production' pour etre charge par l'API.

### 7.3 Monitoring du Drift avec Evidently AI

Un script de surveillance Evidently AI compare les distributions de donnees en production aux donnees de reference :

- Data Drift : Test Kolmogorov-Smirnov sur les variables numeriques.
- Text Drift : Divergence Jensen-Shannon appliquee aux features TF-IDF.
- Alertes : Notification automatique si la performance de l'API descend sous le seuil d'Accuracy de 0.70.

## 8. Application Cliente & API

- Backend Django REST & FastAPI : API hybride (authentification, historique, predictions).
- Application Flutter : Visualisation 2D interactive des clusters, estimation en direct, quiz citoyen, et integration de l'Assistant IA global pour guider l'utilisateur.

## 9. Esprit Critique et Retrospective

- **Dataset Synthetique** : L'obtention d'une Accuracy de 99.7%+ revele un dataset fortement separable et de nature synthetique. En conditions reelles, cela requerrait des verifications strictes contre les risques de fuite de donnees.
- **Gestion des Dependances** : La correction des conflits de versions entre Gensim, Scipy et Numpy illustre la necessite d'isoler et geler les environnements de production en contexte industriel.

**FIN DU RAPPORT TECHNIQUE OFFICIEL**