

RAPPORT TECHNIQUE DE PROJET

ECO-SMART CLASSIFIER

Pipeline Multimodal de Classification de Dechets et d'Estimation de Prix en Tunisie

Workflow complet d'ingenierie des donnees et de Machine Learning appliqué au developpement durable.

De l'exploration exploratoire a l'imputation, modelisation predictive supervisee, clustering, traitement de texte naturel (NLP), pipeline multimodal, et infrastructure MLOps complete (DVC, MLflow, CI/CD, Monitoring).

[EMPLACEMENT CAPTURE D'ECRAN : Logo ou Illustration du Systeme Eco-Smart]

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

Projet de Fin d'Etudes / Travaux Pratiques Industriels

Destine a l'Evaluation Academique

Environnement Deploiement : Flutter Client, Django REST API & FastAPI Predictor

Date de Finalisation : Mai 2026

Table des Matieres

Section	Page
1. Introduction et Perimetre du Projet	3
2. Description du Dataset et Specifications Techniques	4
3. Module 1 : Exploration, Nettoyage et Analyse des Donnees	5
4. Module 1 : Traitement des Outliers et Strategies d'Imputation	6
5. Module 2 : Modelisation Supervisee (Classification)	7
6. Module 2 : Modelisation Supervisee (Regression du Prix)	8
7. Module 2 : Selection de Features avec SHAP Values	9
8. Module 3 : Clustering Non-Supervise (Segmentation)	10
9. Module 4 : NLP - Pretraitement et Vectorisation	11
10. Module 4 : NLP - Comparaison des Classificateurs	12
11. Module 5 : Pipeline Multimodal & Strategie de Fusion	13
12. Module 6 : MLOps - Versionnement de Donnees avec DVC	14
13. Module 6 : MLOps - Tracking des Experiences avec MLflow	15
14. Module 6 : MLOps - Tests Unitaires et CI/CD	16
15. Module 7 : Infrastructure FastAPI et Monitoring	17
16. Application Cliente « Eco-Smart Classifier »	18
17. Charte de l'IA, Journal de Prompts & Esprit Critique	19
18. Conclusion Generale et Perspectives	20

1. Introduction et Perimetre du Projet

1.1 Contexte et Enjeux

Dans le cadre de la transition ecologique mondiale et de l'economie circulaire, la valorisation des dechets represente un axe de developpement prioritaire pour la Tunisie. Actuellement, la gestion des dechets y est confrontee a des defis structurels majeurs : absence de tri selectif systematique, faible visibilite des circuits de recyclage, et manque de motivation des citoyens. Le projet Eco-Smart Classifier vise a repondre a ces problemes grace a une application associant Machine Learning et interfaces interactives.

1.2 Objectif du Projet

Le but de ce projet est de concevoir et deployer un pipeline d'ingenierie des donnees et de Machine Learning complet de bout-en-bout (End-to-End) capable d'automatiser le tri de dechets et d'estimer leur prix de revente pour encourager les citoyens et les centres a recycler.

1.3 Les Quatre Modules Interconnectes

- **1. Data Engineering** : Nettoyage, traitement des anomalies et imputation intelligente sur un dataset bruite.
- **2. Machine Learning Supervise** : Classification multiclasse de la categorie de dechets et regression lineaire/non-lineaire de la valeur marchande estimee.
- **3. Machine Learning Non-Supervise** : Segmentation par clustering K-Means pour caracteriser des familles de matériaux sans etiquette cible.
- **4. Module NLP d'Interface** : Traitement du langage naturel pour extraire des caracteristiques et identifier les dechets depuis des comptes-rendus textuels.

[EMPLACEMENT CAPTURE D'ECRAN : Architecture Globale de la Chaine de Valeur]

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

2. Description du Dataset et Specifications

2.1 Description des Variables (9 Colonnes)

Le dataset brut comprend 10 500 enregistrements destines a l'apprentissage. Il se compose des variables suivantes :

- Poids (numerique, Kg) : Poids physique du lot de dechets (comporte environ 10% de valeurs manquantes).
- Volume (numerique, m3) : Volume occupe par le dechet (comporte des anomalies extreres).
- Conductivite (numerique, S/m) : Indicateur d'electricite, utile pour separer les metaux.
- Opacite (numerique, %) : Taux d'opacite lumineuse du dechet.
- Rigidite (numerique, score) : Score mesurant la resistance structurelle.
- Source (categorielle) : Provenance du lot (Usine_A, Municipal, Centre_Tri, etc.).
- Rapport_Collecte (textuelle) : Description en langage naturel redigee par le collecteur.
- Prix_Revente (numerique, cible regression) : Valeur estimative du lot.
- Categorie (cible classification) : Type de materiau (Plastique, Verre, Metal, Papier).

2.2 Anomalies et Masquages Volontaires

Afin de tester la robustesse des traitements des etudiants, le dataset contient volontairement :

- ~10% de NaN dans la colonne Poids (valeurs manquantes a reconstituer).
- Des outliers massifs (outliers physiques aberrants) dans la colonne Volume.
- 514 labels Categorie cibles manquants a predire apres finalisation du modele.

2.3 Protocole de Division des Donnees (Split)

Pour valider scientifiquement nos modeles, le split du dataset est fixe au ratio 70:15:15 :

- 70% pour le Train (apprentissage des modeles)
- 15% pour la Validation (tuning des hyperparametres et selection de modeles)
- 15% pour le Test (evaluation de la generalisation finale).

Ce fractionnement est effectue avec stratification sur la Categorie pour preserver les proportions des classes.

[EMPLACEMENT CAPTURE D'ECRAN : Visualisation des distributions des variables et ratios originaux]

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

3. Module 1 : Exploration, Nettoyage et Analyse

3.1 Exploration des Variables Cibles et Distributions

L'étude préliminaire révèle des corrélations évidentes : la Conductivité permet d'isoler quasi-parfaitement les métaux. La Rigidité est très élevée pour le Verre et le Métal. Le Volume et le Poids sont liés par la densité propre à chaque catégorie de déchets.

3.2 Mécanisme de Valeurs Manquantes (MCAR / MAR / MNAR)

L'analyse quantitative des NaN sur la variable Poids établit la typologie du mécanisme de perte de données :

- MCAR (Missing Completely At Random) : La probabilité de perte est indépendante de toutes les variables.
- MAR (Missing At Random) : La perte est liée à une autre variable observée (ex: certaines sources ne mesurent pas le poids).
- MNAR (Missing Not At Random) : La probabilité de manque dépend de la valeur manquante elle-même (ex: déchets trop lourds non pesables).

Dans notre cas, la présence de NaN sur le Poids montre une corrélation légère avec la variable Source, ce qui nous oriente vers une hypothèse MAR.

3.3 Encodage des Catégoriels & Feature Engineering

Les variables qualitatives comme 'Source' ont subi un encodage One-Hot (variables binaires) pour être assimilables par les algorithmes de scikit-learn. De plus, nous avons enrichi l'espace de features :

- Densité = Poids / Volume (très discriminante pour séparer le papier de faible densité et le verre).
- Log_Volume = $\log(1 + \text{Volume})$ afin de réduire la dissymétrie des valeurs de Volume.

[EMPLACEMENT CAPTURE D'ECRAN : Visualisation Matrice de Correlation de Pearson apres Feature Engineering]
(Inserez ici l'image de capture correspondante lors de la finalisation du document)

4. Module 1 : Traitement des Outliers et Imputation

4.1 Traitement des Outliers (IQR Capping)

Certaines mesures de Volume contenaient des valeurs aberrantes de plusieurs ordres de grandeur. Nous avons applique la methode de l'ecart interquartile (IQR) :
Tout Volume depassant $Q3 + 1.5 * IQR$ a ete ramene a cette borne superieure (capping) pour eviter de perturber les modeles lineaires et le calcul des distances de KNN.

4.2 Comparaison Quantitative des Strategies d'Imputation

Nous avons masque artificiellement 10% de donnees de Poids connues pour calculer le RMSE de reconstruction :

Strategie testee	RMSE Reconstruction	Statut de Validation
Mediane (Baseline)	112.45	Rejetee (Biais eleve)
KNN Imputer (k=5)	43.12	Retenue (Optimale)
Iterative Imputer (MICE)	48.76	Rejetee (Calcul couteux)

4.3 Normalisation et Mise a l'Echelle

Puisque KNN calcule des distances euclidiennes, nous avons applique un StandardScaler sur toutes les variables numeriques afin qu'aucune variable n'ecrase artificiellement les autres lors du calcul de distance.

[**EMPLACEMENT CAPTURE D'ECRAN : Notebook 01 - Visualisation des Donnees avant et apres Imputation KNN**]
(Inserez ici l'image de capture correspondante lors de la finalisation du document)

5. Module 2 : Modelisation Supervisee (Classification)

5.1 Entrainement et Tuning par GridSearchCV

L'objectif est d'identifier la Categorie de dechet. Nous avons entraine plusieurs algorithmes avec recherche par grille (GridSearchCV) sur 5 plis de validation croisee.

Modele	Accuracy (val)	F1 pondere (val)	Analyse critique
Regression Logistique	0.9725	0.9725	Bonne baseline mais moins robuste sur non-linearite.
RandomForestClassifier	0.9964	0.9964	Excellent, tres stable face au bruit.
GradientBoosting	0.9971	0.9971	Performance maximale, plus longue a entrainer.

5.2 Performance sur le Jeu de Test

Sur l'ensemble de test independant, le modele RandomForest optimal a obtenu une Accuracy de 0.9978. La matrice de confusion ne montre que de tres rares confusions mineures entre Papier et Carton.

[EMPLACEMENT CAPTURE D'ECRAN : Matrice de Confusion de la Classification (RandomForest)]

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

6. Module 2 : Modelisation Supervisee (Regression du Prix)

6.1 Estimation du Prix de Revente (TND)

Nous avons modelise la variable Prix_Revente par regression supervisee. Le but est de prevoir avec precision la valeur marchande en dinars tunisiens (TND) a partir des mesures physiques.

Algorithme	MAE	RMSE	R2 (Score)	Evaluation Critique
Regression Lineaire	106.54	706.25	0.0088	Totalement inadequat (relations complexes).
RandomForestRegressor	3.83	36.51	0.9974	Tuning optimal (GridSearchCV). Tres robuste.
GradientBoostingRegressor	19.63	82.94	0.9863	Performances correctes mais ecart notable.

6.2 Analyse de l'Erreur de Regression

Sur l'ensemble de validation, la MAE de 3.83 (environ 4 millimes d'erreur moyenne) replete une grande precision globale. Cependant, l'ecart type de l'erreur est plus eleve sur le jeu de test, ce qui s'explique par la presence de quelques dechets volumineux atypiques (outliers non captes).

[EMPLACEMENT CAPTURE D'ECRAN : Graphique Predictions vs Valeurs Reelles pour le Prix de Revente]

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

7. Module 2 : Selection de Features & SHAP Values

7.1 Principe des SHAP (SHapley Additive exPlanations)

Afin de rompre l'effet 'boite noire' de l'algorithme RandomForest, nous avons applique les SHAP Values. Cette methode de la theorie des jeux attribue a chaque feature un score d'importance locale representant sa contribution exacte a la prediction de chaque dechet.

7.2 Explicabilite Globale

L'analyse SHAP etablit la hierarchie d'importance suivante pour classifier les materiaux :

- Conductivite : Decisive pour predire la classe Metal (valeurs elevees tirent fortement la prediction).
- Rigidite : Decisive pour la classe Verre.
- Opacite : Discrimine les dechets transparents (Verre) des dechets opaques (Plastique/Papier).
- Densite : Variable derivee tres influente pour separer Plastique et Papier.

7.3 Reduction de l'Espace de Features

Grace aux SHAP Values, nous avons identifie 3 colonnes issues de l'encodage One-Hot de Source n'ayant aucune influence sur la cible (SHAP median egal a zero). En retirant ces colonnes, nous avons reduit la dimension de 20%, ce qui accelere l'inference sur l'API sans aucune degradation de l'Accuracy.

[EMPLACEMENT CAPTURE D'ECRAN : Graphique SHAP Summary Plot du Modele RandomForest]

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

8. Module 3 : Clustering Non-Supervise (Segmentation)

8.1 Methode du Coude (Elbow Method)

Dans ce module, nous ignorons complètement les étiquettes Catégorie. Nous cherchons à segmenter les déchets de manière non-supervisée avec K-Means. L'évaluation de la distorsion pour k de 1 à 10 montre un point de flexion net (coude) à k = 4, confirmant la structure naturelle en 4 groupes.

8.2 Reduction PCA 2D

Nous projetons les 6 variables numériques standardisées sur les deux composantes principales (PCA 2D). La visualisation révèle quatre regroupements homogènes bien distincts dans le plan.

8.3 Caracterisation des 4 Clusters Identifies

- **Cluster 0 (Metaux)** : Haute conductivité, rigidité forte et densité élevée.
- **Cluster 1 (Plastiques)** : Densité faible, forte opacité, conductivité nulle.
- **Cluster 2 (Papier/Carton)** : Rigidité minimale, densité très faible.
- **Cluster 3 (Verre)** : Rigidité maximale, opacité nulle (transparence totale).

[EMPLACEMENT CAPTURE D'ECRAN : Visualisation des 4 Clusters K-Means dans l'Espace PCA 2D]

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

9. Module 4 : NLP - Pretraitement et Vectorisation

9.1 Pretraitement Textuel (Pipeline NLP)

Les comptes-rendus dans Rapport_Collecte sont rediges manuellement. Notre pipeline de nettoyage inclut :

- Nettoyage regex : Suppression de la ponctuation, des caracteres speciaux et chiffres.
- Tokenisation : Segmentation en mots individuels.
- Stopwords : Elimination des mots vides francais generiques (le, la, et...) et propres au domaine (rapport, collecte, lot).
- Stemming : Rapprochement morphologique via l'algorithme Snowball Stemmer (ex: 'bouteilles' et 'bouteille' -> 'bouteill').

9.2 Comparaison des Quatre Vectorisations

- **1. Bag of Words (BoW)** : Simple denombrement des frequences. Rapide mais ignore le contexte sémantique.
- **2. TF-IDF (Uni + Bigrammes)** : Valorise les mots informatifs rares (ex: 'bris verre', 'bouteill plastiq'). C'est notre baseline de reference.
- **3. Word2Vec (Gensim)** : Embeddings continus capturant la proximite semantique. Plus robuste aux synonymes.
- **4. FastText** : Avantageux pour les coquilles d'écriture frequentes dans les rapports (ex: 'plastiq', 'carthon').
- **5. CamemBERT (Sentence Transformers)** : Modele pre-entraine BERT francais pour une representation contextuelle complete (Bonus).

[EMPLACEMENT CAPTURE D'ECRAN : Code du Pipeline de Vectorisation ColumnTransformer]

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

10. Module 4 : NLP - Comparaison des Classificateurs

10.1 Comparaison des Classificateurs de Texte

Nous avons applique les representations textuelles TF-IDF a plusieurs modeles pour predire la Categorie :

Algorithme Classificateur	Accuracy (Val)	F1-Score (Val)	Analyse et Robustesse
Naive Bayes Multinomial	0.9120	0.9105	Tres rapide, mais suppose l'independance des mots.
LinearSVC (SVM Lineaire)	0.9780	0.9782	Excellente separation en haute dimension.
Regression Logistique	0.9650	0.9648	Robuste et simple d'interpretation.
Random Forest	0.9540	0.9535	Moins performant en haute dimension creuse.

10.2 Robustesse aux Coquilles (FastText)

L'evaluation sur des rapports contenant des fautes d'orthographe (ex: 'bouteille' au lieu de 'bouteille') montre que FastText conserve une precision de 94.5% grace a la prise en compte des n-grammes de caracteres, la ou TF-IDF sans stemming chute a 78%.

[EMPLACEMENT CAPTURE D'ECRAN : Matrice de Confusion de la Classification de Textes (LinearSVC)]
(Inserez ici l'image de capture correspondante lors de la finalisation du document)

11. Module 5 : Pipeline Multimodal & Strategie de Fusion

11.1 Contexte et Enjeux de la Multimodalite

Dans une application industrielle de tri, il est optimal de combiner les informations physiques du dechet (Poids, Rigidite) et les descriptions textuelles du collecteur. C'est l'objectif du pipeline multimodal.

11.2 Fusion par Concatenation Sparse (hstack)

La fusion s'opere au niveau des features (Early Fusion) via un ColumnTransformer de scikit-learn. Les variables numeriques standardisees sont concatenees a la matrice sparse TF-IDF generee à partir des textes. Ce pipeline integre est encapsule dans un unique estimateur pour prevenir le leakage lors du cross-validation.

11.3 Ponderation et Stacking de Modeles

Nous avons teste une strategie de Stacking : les probabilites issues d'un classificateur de textes (SVM) et d'un classificateur numerique (RandomForest) sont passees a un Meta-Classificateur (Regression Logistique). Ce Stacking ameliore l'Accuracy de test de +0.4% par rapport au meilleur modele simple.

[EMPLACEMENT CAPTURE D'ECRAN : Code source de la definition du Pipeline Multimodal]

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

12. Module 6 : MLOps - Versionnement de Donnees avec DVC

12.1 Problematique du Versionnement en Machine Learning

Stocker des fichiers de donnees (CSV de 10 500 lignes) ou des fichiers de modeles serialises (PKL de 1.4 Mo) directement dans Git alourdit le depot et nuit a la tracabilite des versions. DVC (Data Version Control) permet de resoudre ce probleme en stockant les donnees dans un stockage externe (cache local ou cloud) tout en versionnant de legers fichiers pointeurs (.dvc) dans Git.

12.2 Structure du Pipeline DVC (dvc.yaml)

Notre pipeline DVC est structure sous forme de DAG (Graphe Oriente Acyclique) contenant deux etapes :

1. preprocess : Nettoie le dataset, impute via KNN, extrait les features, et effectue le split stratifie.
 - Entrees : data/raw_dataset.csv, src/preprocess.py
 - Sorties : data/train_preprocessed.csv, data/test_preprocessed.csv
2. train : Entraîne le pipeline multimodal et exporte le modele final.
 - Entrees : data/train_preprocessed.csv, src/train.py
 - Sorties : models/multimodal_model.pkl

12.3 Reproductibilite Complete

Executer la commande 'dvc repro' permet de rejouer l'integralite du pipeline en cascade. Si aucun fichier n'a change, DVC utilise son cache pour eviter des calculs inutiles.

[EMPLACEMENT CAPTURE D'ECRAN : Graphe DAG du pipeline genere par la commande 'dvc dag']

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

13. Module 6 : MLOps - Tracking des Experiences avec MLflow

13.1 Suivi des Hyperparametres et Metriques

Pendant la phase de recherche par grille (GridSearchCV), toutes les runs de modelisation ont ete enregistrees sur un serveur MLflow local configure avec une base SQLite (mlflow.db). Nous avons loggue les hyperparametres (n_estimators, max_depth, learning_rate) ainsi que les metriques liees (Accuracy, F1-Score, RMSE, MAE, R2).

13.2 Comparaison d'au moins 5 Experiences

Nous avons compare 5 configurations de modeles dans le tableau de bord MLflow :

1. baseline_logistic_regression : F1-Score = 0.9725
2. rf_default_params : F1-Score = 0.9920
3. rf_tuned_gridsearch (Meilleur modele classification) : F1-Score = 0.9964
4. gradient_boosting_tuned : F1-Score = 0.9971
5. multimodal_stacking_pipeline : F1-Score = 0.9978

13.3 Model Registry et Promotion

Le meilleur modele de classification multimodal 'rf_tuned_gridsearch' a ete enregistre dans le Model Registry de MLflow sous le nom 'EcoSmartClassifier'. Il a ensuite ete promu au statut de Production pour etre directement deployable.

[EMPLACEMENT CAPTURE D'ECRAN : Interface MLflow avec la comparaison des 5 experiences et courbes]

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

14. Module 6 : MLOps - Tests Unitaires et CI/CD

14.1 Tests Unitaires avec pytest

Afin de garantir la robustesse de l'application, nous avons developpe un ensemble de tests unitaires dans le dossier tests/. Les tests couvrent :

- Le schema des donnees : Verification que toutes les colonnes requises sont presentes.
- La qualite post-imputation : S'assurer qu'il ne reste aucun NaN sur la colonne Poids apres KNN.
- Le pipeline NLP : Validation du bon nettoyage (regex, stopwords, stemming).
- Performance minimale : S'assurer que l'Accuracy de classification sur le jeu de test depasse 0.70.
- L'API FastAPI : Test de requetes sur l'endpoint /predict.

14.2 Rapport de Couverture de Code (Coverage)

Nous executons les tests avec la commande 'pytest --cov=src --cov-fail-under=70'. Le taux de couverture minimal de 70% est valide de maniere stricte.

14.3 Integration Continue (CI/CD) via GitHub Actions

A chaque push sur le depot GitHub, le workflow .github/workflows/ci.yml verifie :

- Le linting (black, flake8, isort) pour valider la conformite du style PEP8.
- L'execution de la suite de tests unitaires.
- Le build de l'image Docker de l'API et son push vers le registry.

[EMPLACEMENT CAPTURE D'ECRAN : Historique des pipelines GitHub Actions avec statut vert et couverture de code]

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

15. Module 7 : Infrastructure FastAPI et Monitoring

15.1 Serving du Modele via FastAPI

L'API d'inference est developpee avec FastAPI, un framework python moderne et tres performant. L'endpoint /predict accepte en entree un objet JSON decrivant le dechet et renvoie la Categorie et le Prix estime. L'API est containerisee via un Dockerfile et s'execute de maniere isolee.

15.2 Monitoring du Drift avec Evidently AI

En production, les donnees utilisateurs peuvent deriver par rapport au dataset d'entrainement. Le script de monitoring s'appuie sur Evidently AI :

- Data Drift Numerique : Test de Kolmogorov-Smirnov sur Poids et Volume pour detecter des decalages de distribution.
- Text Drift : Calcul de la divergence de Jensen-Shannon sur les distributions de probabilites TF-IDF des textes.
- Alertes de Performance : Si la precision de prediction de l'API descend sous 70%, une alerte structuree est enregistree au format JSON.

15.3 Grafana + Prometheus

Pour visualiser le drift et la latence de l'API en temps reel, les metriques sont exposees via Prometheus et affichees dans un tableau de bord Grafana en production (Bonus).

[EMPLACEMENT CAPTURE D'ECRAN : Dashboard de Monitoring de Drift avec Evidently AI et metrics]

(Inserez ici l'image de capture correspondante lors de la finalisation du document)

16. Application Cliente « Eco-Smart Classifier »

16.1 Architecture de l'Application

L'application Flutter propose une interface premium, developpee avec des palettes de couleurs harmonieuses, une typographie moderne (Outfit/Inter) et des animations fluides. Elle s'articule autour de trois sections :

16.2 Les Trois Onglets Principaux

- **1. Dashboard Data** : Visualisation interactive des distributions physiques et projection 2D PCA des 4 clusters de dechets.
- **2. Prediction Manuelle** : L'utilisateur manipule des curseurs interactifs (Poids, Volume, Conductivite) et observe la prediction de Categorie et l'estimation de Prix se mettre a jour instantanement.
- **3. Assistant Intelligent NLP** : Une zone de texte permet de saisir une description (ex: 'lot de vieilles bouteilles de biere en verre brisees') pour appeler l'API de prediction.

16.3 Bouton Flottant Global Assistant IA

Un bouton flottant violet de l'IA (Eco-Assistant) est disponible sur tous les ecrans. Il ouvre une interface de chat avec un LLM local specialise pour repondre aux questions de tri et d'usage de l'application.

[EMPLACEMENT CAPTURE D'ECRAN : Captures d'ecran de l'application Flutter (Dashboard, Simulation, Assistant)]
(Inserez ici l'image de capture correspondante lors de la finalisation du document)

17. Charte de l'IA, Journal de Prompts & Esprit Critique

17.1 Respect de la Charte IA du Projet

Ce projet s'inscrit dans un cadre d'utilisation raisonnée et éthique des Assistants IA. Nous avons respecté le code couleur imposé par la charte IA :

- Zone Rouge (IA Interdite) : Écriture des tests unitaires pytest, première version du prétraitement NLP et analyses EDA fondamentales (réalisées par l'étudiant).
- Zone Orange (IA pour Structuration) : Configuration des fichiers de pipeline DVC/MLflow et debug.
- Zone Verte (IA Libre) : Optimisation de code, Dockerfile, scripts CI/CD, templates Evidently AI.

17.2 Le Fichier Obligatoire PROMPTS.md

Toutes les interactions avec les IA de génération de code ont été consignées dans le fichier PROMPTS.md, mentionnant les requêtes soumises, le code obtenu et les corrections critiques apportées par l'étudiant.

17.3 Esprit Critique et Retrospective

L'obtention immédiate de métriques d'Accurarcy supérieures à 99.6% a été analysée avec recul. Il s'agit vraisemblablement d'un dataset synthétique. En conditions industrielles réelles, une telle séparabilité serait suspecte de fuite de données (data leakage). De plus, la résolution de conflits de versions (Gensim/Scipy) a souligné l'importance d'un lock strict des dépendances.

[EMPLACEMENT CAPTURE D'ECRAN : Extrait du fichier PROMPTS.md de suivi des interactions IA]
(Insérez ici l'image de capture correspondante lors de la finalisation du document)

18. Conclusion Generale et Perspectives

18.1 Bilan Technique

Le projet Eco-Smart Classifier a permis de concevoir une architecture logicielle complete, connectee et performante. L'utilisation conjointe de modeles de Machine Learning supervises et non-supervises, du traitement de texte sémantique NLP et des outils MLOps repond aux exigences de robustesse et de tracabilite des projets Data Science industriels modernes.

18.2 Competences Acquises

- Exploration, nettoyage et imputation KNN d'un dataset bruite.
- Conception de pipelines multimodaux de bout-en-bout avec scikit-learn.
- Maitrise des outils de reproductibilite (DVC) et de tracking des runs (MLflow).
- Deploiement de micro-services conteneurises (FastAPI, Docker) et de clients cross-plateformes (Flutter).
- Monitoring de la derive de donnees (drift) avec Evidently AI et Grafana.

18.3 Perspectives de Developpement

Afin d'aller plus loin, plusieurs ameliorations sont envisagees :

1. Deploiement reel de l'API sur un fournisseur Cloud comme Hugging Face Spaces ou Railway.
2. Integration de modeles d'embeddings sémantiques plus volumineux (CamemBERT) sur l'API.
3. Integration de capteurs de tri physiques connectes (IoT) transmettant les donnees en temps reel a l'application.

FIN DU LIVRABLE ACADEMIQUE - PROJET ECO-SMART